

LLM 对话历史管理实验报告

LLM 对话历史管理实验报告

实验目的

本实验旨在实现 LLM 对话系统的历史管理功能，解决长对话上下文限制问题。具体目标包括：

1. 实现对话历史压缩机制，控制上下文长度
2. 开发关键信息提取功能，保存重要对话内容
3. 实现聊天历史搜索功能
4. 掌握对话摘要生成与信息检索技术

实验内容

1. 对话历史压缩机制

压缩触发条件： - 对话轮数超过 5 轮 - 上下文总字符数超过 3000 字符

压缩策略： - 保留最近 30%的对话消息 - 对前 70%的对话进行摘要压缩 - 生成结构化摘要，保留关键信息

核心函数： - `calculate_context_length()`: 计算上下文总长度 - `count_conversation_rounds()`: 统计对话轮数 - `summarize_conversation()`: 生成对话摘要 - `check_and_summarize()`: 检查并执行压缩

2. 关键信息提取功能

5W 规则提取： - **Who (谁)**: 涉及的主要人物或角色 - **What (做了什么)**: 用户的主要需求和行动 - **When (什么时候)**: 时间相关信息 - **Where (在何处)**: 地点相关信息 - **Why (为什么)**: 做某事的目的或原因

提取流程： 1. 每 5 轮对话自动触发提取 2. 调用 LLM 分析对话内容 3. 解析 JSON 格式的提取结果 4. 保存到本地日志文件 `D:\chat-log\log.txt`

3. 聊天历史搜索功能

搜索触发方式: - 输入命令 `/search` + 查询内容 - 输入包含关键词的语句 (如"查找聊天历史")

搜索实现: - 读取日志文件中的历史记录 - 构建搜索提示词, 包含历史记录和当前问题 - 调用 LLM 进行语义搜索和回答生成 - 返回与查询相关的历史信息

4. 新增工具扩展

添加 `search_chat_history` 工具:

```
{
  "name": "search_chat_history",
  "description": "搜索聊天历史记录, 结合用户问题和历史记录给出完整回答",
  "parameters": {
    "user_question": {"type": "string", "description": "用户的问题或查询内容"}
  }
}
```

实验结果

功能验证

功能模块	测试结果	说明
对话压缩	通过	自动检测并压缩长对话
关键信息提取	通过	按 5W 规则提取并保存
聊天历史搜索	通过	支持命令触发和关键词触发
日志持久化	通过	自动创建目录和文件

输出示例

对话压缩输出:

[系统] 检测到对话历史较长 (6轮, 约3500字符), 正在压缩...

[系统] 压缩完成! (3轮, 约1200字符)

关键信息提取输出:

[系统] 对话已达到 5 轮, 正在提取关键信息...

[系统] 已提取并保存 2 条关键信息到 `D:\chat-log\log.txt`

日志文件格式:

```
[  
  {  
    "时间": "2024-01-15 10:30:00",  
    "Who": "用户",  
    "What": "查询天气预报",  
    "When": "2024-01-15",  
    "Where": "北京",  
    "Why": "了解今日天气情况"  
  }  
]
```

实验总结

技术要点

1. 上下文管理策略：通过压缩和摘要平衡对话连贯性与 API 成本
2. 信息提取规范：采用 5W 规则确保提取信息的完整性和结构化
3. 搜索机制设计：结合 LLM 语义理解实现智能搜索
4. 持久化存储：使用 JSON 格式保存，便于读取和解析

学习收获

通过本实验，掌握了以下核心技能：

- 对话历史管理的策略和实现方法
- LLM 辅助的文本摘要生成技术
- 关键信息提取与结构化存储
- 基于语义的历史记录搜索
- 文件系统操作与持久化

改进方向

1. 增加对话历史的加密存储，提高安全性
2. 实现历史记录的分页查询功能
3. 添加搜索结果的排序和过滤
4. 支持多关键词组合搜索